



T.C.

DÜZCE ÜNİVERSİTESİ

YÖNETİM BİLİŞİM SİSTEMLERİ BÖLÜMÜ

MAKİNE ÖĞRENMESİ DERSİ

Random Forest Algoritma Sorularının Yanıtlanması Raporu

AD SOYAD: Berkay YILMAZ



ÖĞRENCİ NO: 242211075

DERS HOCASI

Dr. Öğr. Fatma Betül KARA ARDAÇ

SORULAR

1-) Model overfitting yapıyor mu ?




--- Model Değerlendirme Sonuçları ---
RMSE (Kök Ortalama Kare Hata) : 4374.65
MAE (Ortalama Mutlak Hata) : 2540.50
R² (Belirleyicilik Katsayısı) : 0.8695

Modelimizde hiperparametre optimizasyonu kullanarak ağaç derinliğini max “5” olarak sınırladığımız ve 5 fold cross validation (5 katlı çapraz doğrulama) yaptığımız için modelin genelleme yeteneği artırılmış oldu ve bize problem yaratabilecek düzeyde overfitting oluşmasını önlemiş oldu. Test veri setinden elde etmiş olduğumuz yaklaşık %87 ‘lik R² skor değeri, modelin veriyi ezberlemediğini ve yeni verilerde gayet başarılı tahminlerde bulunabildiğini göstermektedir. Yukarıda yer alan grafiklerde de net bir şekilde görüldüğü üzere, modelimiz eğitim aşamasında görmediği veriler üzerinde (test verileri) oldukça tutarlı tahminler vermiştir.

2-) Random Forest neden Decision Tree’ den daha iyi performans gösterir ?

Karar ağaçları tek bir ağaç oluşturur ve eğitim verilerini ezberlemeye meyillidir. Rastgele orman ise eğitim veri setinden rastgele alt kümeler seçerek yüzlerce belki de binlerce farklı karar ağacı oluşturur. Regresyon problemlerinde bu ağaçların ürettiği sonuçların ortalamasını alarak nihai kararı verir. Böylelikle varyans düşer , overfitting olasılığı engellenir ve tek bir ağaca göre çok daha tutarlı ve doğru tahminlerde bulunur.

3-) Modelin avantaj ve dezavantajları nelerdir ?



Avantajlar : Lineer olmayan karmaşık ilişkileri çok iyi yakalar ve aykırı değerlere karşı karar ağaçlarına ve basit regresyon modellerine göre daha dirençlidir. Ayrıca modelin karar mekanizmasında hangi değişkenlerin daha önemli olduğunu kolaylıkla belirlememizi sağlar. Modelin en büyük avantajlarından biri olan rapora da eklediğimiz grafikte net bir şekilde görüldüğü gibi sigara içme durumu gibi değişkenlerin sigorta masrafları üzerinde yüksek etkisi bulunduğunu kolaylıkla bize sunabilmektedir.

Dezavatajlar : Tek bir karar ağacı gibi kolay bir şekilde görselleştirilip adım adım yorumlanması zordur bu nedenle bir kara “kutu modeli” olarak kabul edilir. Ayrıca arka planda çok fazla ağaç eğitildiğinden dolayı hesaplama maliyeti oldukça yüksektir ve eğitim ve tahmin süreleri basit modellere nazaran daha uzun sürmektedir.

4-) Aşağıdaki hiperparametreleri açıklayınız :

- **n_estimators :** Random Forest içerisindeki toplam ağaç sayısıdır. Bu sayının artması genel olarak modeli pozitif yönde iyileştirse de işlem süresini uzatır.
- **max_depth :** Bir karar ağacının kökten yapraklara kadar inebileceği maksimum derinlik seviyesidir. Bu değer modeli basitleştirmek ve overfitting olasılığını azaltmak için sınırlandırılır.
- **min_samples_split :** Bir düğümün daha alt dallara bölünebilmesi için o düğümde bulunması gereken minimum örneklem sayısıdır.
- **max_features :** Ağacın her bir düğümünde en iyi bölünmeyi ararken göz önünde bulunduracağımız maksimum rastgele özellik sayısıdır. Bu değer ağaçların birbirinden farklı ve çeşitli olmasını sağlamaktadır.